

基于Spark的汽车大数据分析与决策支持平台——MVP方案

一、MVP目标

在有限实训周期内完成一个可运行、可演示的消费者购车推荐闭环：消费者输入预算及购车偏好，系统从汽车数据集中筛选并计算推荐结果，返回 3—5 款车型及可解释的推荐原因，并支持查看关键参数和简单车型对比。

MVP 的重点不是建设完整汽车平台，而是证明以下链路能够跑通：

汽车原始数据 → Spark 数据处理 → 用户输入条件 → 车型筛选与评分 → 推荐车型与原因 → 页面展示

二、目标用户与使用流程

目标用户为近期有购车需求、但缺少汽车专业知识的普通消费者。

基本使用流程如下：

- 1 用户进入购车推荐页面；
- 2 输入预算上限和下限；
- 3 选择车型、能源类型、品牌或使用场景等偏好；
- 4 点击“开始推荐”；
- 5 系统返回 3—5 款推荐车型；
- 6 用户查看每款车的关键参数、匹配得分和推荐原因；
- 7 用户选择其中 2—3 款车型进行简单对比。

三、MVP功能范围

必须完成

- 1 一份结构统一、可以运行 Spark 任务的汽车数据集；
- 2 使用 PySpark 完成数据清洗、字段转换和特征处理；
- 3 一个包含预算、车型和能源类型等条件的输入页面；
- 4 基于硬性筛选与加权评分的推荐算法；
- 5 返回 3—5 款车型及结构化推荐原因；
- 6 推荐结果卡片和 2—3 款车型的关键参数对比；
- 7 至少一项能够体现 Spark 处理过程的运行结果或统计图表；
- 8 大模型不可用时仍能正常生成推荐结果和模板化推荐原因。

可以完成

- 接入大模型，将结构化推荐依据改写为更自然的说明；

- 增加价格区间、能源类型或车型分布图；
- 支持用户调整条件后重新推荐；
- 增加推荐结果导出或截图功能。
- 建立与推荐快照隔离的完整配置参数长表和车系月销量表，用于课外探索性关联分析。

明确不做

- 注册、登录、用户中心及权限管理；
- 管理员后台和通用数据增删改查系统；
- 面向厂商的销量预测、生产规划或营销决策；
- 将参数与销量的统计相关性表述为因果影响；
- 在线支付、订单、试驾预约和经销商对接；
- 复杂深度学习模型训练；
- 让大模型直接代替推荐算法。

四、最小数据字段

汽车数据集至少包含以下字段：

字段	用途
车型名称	展示推荐结果
品牌	品牌偏好匹配
指导价	预算筛选与价格匹配
车身类型	轿车、SUV、MPV 等偏好匹配
能源类型	燃油、纯电、插混等偏好匹配
座位数	家庭或多人出行场景匹配
续航里程或油耗	通勤、长途等场景匹配
销量或热度	作为推荐排序的辅助指标

数据缺少某些可选字段时，推荐算法应自动取消对应评分项，不能用虚构数据补齐。

五、推荐算法方案

推荐分为“硬性筛选”和“综合评分”两步。

1. 硬性筛选

- 车辆价格应在用户预算范围内或接近预算上限；
- 车型符合用户选择的车型类型；
- 能源类型符合用户选择；
- 用户未选择的条件不作为限制。

2. 综合评分

候选车辆可以按照以下示例权重进行评分：

评分因素	建议权重
预算匹配度	35%
车型匹配度	20%
能源类型匹配度	20%
使用场景适配度	15%
品牌偏好	5%
销量或热度	5%

权重可以根据实际数据字段调整，但必须在报告中说明评分依据。推荐原因直接读取得分较高的匹配项，例如“价格位于预算中段”“符合纯电 SUV 偏好”“续航适合日常通勤”，以保证推荐结果可解释。

六、大模型在MVP中的位置

大模型属于可选增强功能，不影响 MVP 主链路验收。

程序先产生如下结构化信息：

```
{
  "model": "示例车型A",
  "matched_factors": ["价格符合预算", "纯电SUV", "续航适合城市通勤"],
  "score": 91
}
```

接入大模型时，只允许其根据这些已知信息生成一段自然语言说明，不允许补充数据集中没有的配置或自行更换推荐车型。接口超时、额度不足或网络不可用时，系统立即退回模板化说明，保证现场演示稳定。

七、最小技术方案

- 数据处理：Python、PySpark；
- 数据存储：CSV 或 Parquet，课程要求需要时同步保存至 HDFS；
- 推荐算法：Python 规则筛选与加权评分；
- 页面与轻量接口：Flask、HTML、CSS、JavaScript；
- 数据可视化：ECharts；
- 大模型：兼容 OpenAI 接口格式的模型 API，可选；
- 版本管理：Git。

Flask 只负责加载处理后的数据、接收推荐条件和返回结果，不建设复杂后台业务。

八、四人模块化分工

四人各自负责一个完整子项目，贡献比例统一为 25%。工作量同时考虑代码、测试、文档、运行证据和答辩，不按代码行数机械拆分。

成员	负责子项目	核心交付	贡献比例
成员 A	数据采集与 Spark 数据工程	16888 采集、Spark 清洗、标准数据、统计结果和数据文档	25%
成员 B	推荐算法与 DeepSeek 说明	筛选评分、条件放宽、推荐原因、DeepSeek 降级和算法测试	25%
成员 C	Flask 接口、系统集成与文档交付	数据装载、三个 API、接口测试、架构/验收文档和 Markdown/PDF 构建	25%
成员 D	前端交互与数据可视化	条件表单、推荐卡片、车型对比、ECharts、页面测试和用户手册	25%

代码量仅作参考：四个子项目当前约为 700、550、500、580 行。数据项目代码较多，集成项目代码较少但承担跨模块联调和交付文档；综合工作量接近。详细文件所有权、互审关系和交付内容见 [docs/team-plan.md](#)。

九、MVP验收标准

- 1 用户能够输入预算，并至少选择车型或能源类型中的一项；
- 2 系统能够稳定返回 3—5 款符合条件的车型；
- 3 每款车型至少展示价格、车型、能源类型和两条推荐依据；
- 4 推荐结果由可复现的筛选与评分算法产生，相同输入能够得到一致结果；
- 5 用户能够对比 2—3 款推荐车型的关键参数；
- 6 能够展示 Spark 数据清洗或统计分析的实际运行过程和结果；
- 7 关闭大模型接口后，推荐功能仍然可以完整运行；
- 8 系统不包含登录、后台管理和厂商决策等范围外功能。

十、最终演示脚本

- 1 展示原始汽车数据和 Spark 清洗结果；
- 2 输入一个明确购车需求，例如“预算 15—20 万、纯电 SUV、主要用于城市通勤”；
- 3 展示系统返回的 3—5 款车型、匹配得分和推荐原因；
- 4 选择两款车型进行参数对比；
- 5 演示大模型生成的自然语言推荐说明；
- 6 关闭或跳过大模型接口，再次展示模板化推荐原因，证明核心功能不依赖外部模型。